西安交通大學

博士学位论文

XXXXXXXXXXXXXXXXXXXXX（论文题目不能超过 35 个汉字）

学位申请人：XXX

指导教师：XXX 教授

学科名称：XXXX

XXXX 年 X 月

XXXXXXXXXX XXXXXXXX

A dissertation submitted to

Xi'an Jiaotong University

in partial fulfillment of the requirements

for the degree of

Doctor of Philosophy

By

XXX

Supervisor: (Associate) Prof. XXX

XXXX

XXX XXXX

博士学位论文答辩委员会

XXXXXXXXXXXXXXXXXXXX（论文题目不能超过 35 个汉字）

答辩人：XXX

答辩委员会委员：

XXXXXXXXXX 大学 XXX：XXX（注：主席）

XXXXXXXXXX 大学 XXX：XXX

XXXXXXXXXX 大学 XXX：XXX

XXXXXXXXXX 大学 XXX：XXX

XXXXXXXXXX 大学 XXX：XXX

答辩时间：XXXX 年 X 月 X 日

答辩地点：XXXXXX

摘　要

强化学习（Reinforcement Learning, RL）在诸多序列决策任务中展现出强大的能力。然而，现有算法普遍依赖于理想的观测条件，在向真实世界部署时，智能体常面临复杂观测环境（Complex Observation Environments）带来的严峻挑战。具体而言：一方面，在视觉强化学习中，高维图像极易受环境背景、光照等视觉特征干扰，盲目引入数据增强虽能提升策略泛化能力，但往往会破坏任务相关信息，导致样本效率低下与训练过程极不稳定；另一方面，在离线强化学习的工业或机器人场景中，在线部署时常发生传感器局部故障，导致低维结构化观测信息缺失，使输入状态偏离训练流形，极易引发特征空间崩溃与策略的灾难性失效。上述面对高维视觉干扰与低维物理缺失的表征难题，严重制约了强化学习在真实非平稳环境中的可靠落地。为此，本文聚焦于复杂观测条件下的强化学习应用，从表征优化与策略鲁棒性的维度出发，提出了两种提升智能体训练稳定性与泛化能力的算法：

1） 针对视觉强化学习中因数据增强使用不当导致的训练不稳定与样本低效问题，提出一种任务感知型视觉数据增强选择方法（PICK）。现有视觉 RL 虽然广泛采用多种数据增强变换来抵御环境视觉干扰，但不同增强操作对特定任务状态分布的影响差异巨大，缺乏任务引导的增强极易引入严重噪声并导致值函数估计发散。为此，PICK 方法构建了一种自适应的数据增强选择机制，通过特征编码器提取高维观测的紧凑表征，并利用预测网络动态学习不同数据增强方法在当前任务场景下的最优选用概率。该机制在保留数据多样性以提取可泛化视觉表征的同时，有效限制了对当前任务具有破坏性的增强操作。在 DMControlGB2 通用化基准测试上的实验表明，PICK 方法不仅在未见视觉场景中展现出优异的泛化性能，更在训练稳定性与样本利用效率上显著优于现有先进的视觉强化学习算法。

2） 针对离线强化学习在面对传感器局部失效等结构化信息缺失时，因状态异常导致的策略脆弱与崩溃问题，提出一种基于自监督掩码重建的鲁棒离线强化学习方法（Masked-IQL）。传统离线 RL 算法过度拟合静态完整数据集，缺乏对状态变量内在物理关联的深层理解。为此，本文将在线部署时的局部观测缺失建模为随机掩码（Masking）操作，构建了基于状态特征的掩码自编码器。通过引入状态重建辅助任务，迫使编码器挖掘各维度传感器数据间潜在的物理约束与结构信息，从而将被破坏的残缺状态重新映射回安全的低维数据流形中。同时，为解决表示学习与强化学习联合优化时的梯度冲突，本文设计了表征与决策解耦

* 本研究得到某某基金（编号：）的资助

的训练范式，将重建后的稳定潜变量输入隐式 Q 学习（IQL）网络。实验表明，Masked-IQL 在面对不同比例状态缺失的破坏性测试中表现优异。

关 键 词： 强化学习；复杂观测环境；表征优化；数据增强；离线强化学习；鲁棒控制

论文类型： 理论研究

ABSTRACT

英文摘要撰写要求如下：

（1）用词准确，符合语法；

（2）关键词按相应专业的标准术语写出，尽量从《英语主题词表》中摘选；

（3）如果论文的主体工作得到了有关基金资助，应用英文在摘要第一页的页脚处标注：本研究得到某某基金（编号：）资助；

中文摘要和英文摘要均不要求学位申请人及其指导教师签字。

摘要正文每段开头不空格，每段之间空一行；

The key parts in drip irrigation facilities are emitters. The structural design parameters of emitters can directly affect its performance and the function of the whole drip irrigation system ……

1. Because……

2. Only ……

3. To support ……

KEY WORDS: XXX; XXX; XXX; XXX

每个关键词组的第一个字母大写，其余为小写，每一关键词之间用分号分开，最后一个关键词后不打标点符号。例如：Drip irrigation emitter; RP&M; Hydraulics; Labyrinth flow channel

TYPE OF DISSERTATION: XXXX

须与中文摘要中的论文类型一致；每个单词第一个字母大写，其余为小写。例如：Applied Research

*The work was supported by the Foundation (foundation ID).

论文类型包括：a. 理论研究 (Theoretical Research)；b. 应用基础 (Application Fundamentals)；c. 应用研究 (Application Research)；d. 研究报告 (Research Report)；e. 设计报告 (Design Report)；f. 案例分析 (Case Study)；g. 调研报告 (Investigation Report)；h. 产品研发 (Product Development)；i. 工程设计 (Engineering Design)；j. 工程/项目管理 (Engineering/Project Management)；k. 其它（Others）。

目 录

摘 要 I
ABSTRACT III
主要符号表 IX
1 绪论 1
1.1 研究背景及意义 1
1.2 国内外研究现状 3
1.2.1 视觉强化学习与数据增强研究现状 3
1.2.2 离线强化学习与策略鲁棒性研究现状 4
1.2.3 强化学习中的表示学习机制研究现状 4
1.3 论文主要研究内容 5
1.4 论文组织结构 5
2 相关理论与技术 6
2.1 强化学习与连续控制基础理论 6
2.1.1 马尔可夫决策过程与部分可观测马尔可夫决策过程 6
2.1.2 Actor-Critic 架构 8
2.1.3 最大熵强化学习与 Soft Actor-Critic 算法 10
2.2 离线强化学习与保守价值评估 12
2.2.1 离线强化学习范式与分布偏移问题 12
2.2.2 隐式 Q 学习算法 14
2.3 复杂观测下的表示学习机制 17
2.3.1 视觉强化学习与数据增强表示 17
2.3.2 掩码建模与自监督特征重建 19
3 算法与代码 22
3.1 算法 22
3.2 导入代码 24
4 参考文献与交叉引用 27
4.1 公式、图表的引用 27
4.1.1 引用公式 27
4.1.2 引用其他内容 27
4.2 参考文献 27
5 非正文部分的要求 29
5.1 摘要 29
5.2 主要符号表 30
5.3 攻读学位期间取得的研究成果 30
5.4 答辩委员会会议决议 31

6 本模板已载入的 Packages 32
致谢 33
参考文献 34
附录 35
攻读学位期间取得的研究成果 36
答辩委员会会议决议 38
常规评阅人名单 39
声明

CONTENTS

ABSTRACT (Chinese) I
ABSTRACT (English) III
Glossary IX
1 Introduction 1
1.1 Research Background and Significance 1
1.2 Research Status at Home and Abroad 3
1.2.1 Research Status of Visual RL and Data Augmentation 3
1.2.2 Research Status of Offline RL and Policy Robustness 4
1.2.3 Research Status of Representation Learning in RL 4
1.3 Main Research Content of the Thesis 5
1.4 Thesis Organization 5
2 Related Theory and Technology 6
2.1 Fundamental Theory of Reinforcement Learning and Continuous Control 6
2.1.1 Markov Decision Process and Partially Observable Markov Decision Process 6
2.1.2 Actor-Critic Architecture 8
2.1.3 Maximum Entropy Reinforcement Learning and Soft Actor-Critic 10
2.2 Offline Reinforcement Learning and Conservative Value Estimation 12
2.2.1 Offline Reinforcement Learning Paradigm and Distribution Shift 12
2.2.2 Implicit Q-Learning 14
2.3 Representation Learning Mechanisms under Complex Observations 17
2.3.1 Visual Reinforcement Learning and Data Augmentation Representation 17
2.3.2 Masked Modeling and Self-Supervised Feature Reconstruction 19
3 Algorithm and Code 22
3.1 Algorithm 22
3.2 Input codes 24
4 Crossreferences 27
4.1 Ref equations, tables or figures 27
4.1.1 Ref equations 27
4.1.2 Ref other floatings 27
4.2 References 27
5 Requirements of other parts 29
5.1 Abstracts 29
5.2 Glossary 30
5.3 Achievements 30
5.4 Decisions 31

6 Loaded Packages 32
Acknowledgements 33
References 34
Appendices 35
Achievements 36
Decision of Defense Committee 38
General Reviewers List 39
Declarations

主要符号表

C_v	灌水器流量偏差系数
CS	Computer Science, 计算机科学
D	管道内径/mm
D_e	灌水器流道当量直径/mm
l	管长/m
Linux	is a generic term referring to the family of Unix-like computer operating systems that use the Linux kernel
LVM	Logical Volume Manager, 逻辑卷管理器
n	迷宫流道单元个数/个
q	灌水器流量/L・h-1
q_n	灌水器额定流量/L・h-1
Re	雷诺数
S_q	灌水器流量标准偏差
v	流体的运动粘性系数
X	流态指数

1 绪论

1.1 研究背景及意义

强化学习（Reinforcement Learning, RL）作为解决序贯决策（Sequential Decision Making）问题的核心机器学习范式，其基础理论建立在马尔可夫决策过程（Markov Decision Process, MDP）之上，旨在通过智能体（Agent）与环境（Environment）的持续交互，利用试错机制与延迟奖励信号优化行为策略，从而实现长期累积期望回报的最大化。近年来，随着深度学习（Deep Learning）技术的迅猛发展，深度强化学习（Deep Reinforcement Learning, DRL）将深度神经网络强大的非线性特征提取与高维连续函数逼近能力引入决策框架，在诸多具有极高复杂度的理论控制任务中取得了突破性进展。

然而，现有的大多数深度强化学习算法在理论推导与模型训练中，普遍隐含了一个极其严格的数学假设，即假定训练数据集与测试数据集满足绝对的独立同分布（Independent and Identically Distributed, IID）条件。在理想的仿真验证平台中，状态转移概率矩阵与奖励函数被设定为静态且完全可知，智能体所接收到的状态观测（Observation）呈现出完美的连续性与无噪性。但在面对真实、非平稳的复杂开放环境时，这一理想化假设难以成立。复杂环境中普遍存在的环境动力学微调、观测噪声注入以及状态特征的瞬态扰动，会导致测试阶段的观测数据分布与训练流形发生显著偏离，进而产生严重的分布外（Out-of-Distribution, OOD）泛化难题。当输入状态脱离原始训练分布时，深度神经网络的隐层激活极易产生不可预期的畸变，导致原有特征表征逻辑失效，进而引发策略网络动作输出退化与价值网络评估发散。具体而言，这种由观测分布偏移引发的底层表征危机，在当前强化学习领域的两大重要研究分支——高维视觉强化学习（Visual RL）与低维结构化离线强化学习（Offline RL）中，分别演化出了截然不同却又殊途同归的理论瓶颈。

在高维视觉强化学习研究中，模型通常直接以高维连续的图像像素作为输入，采用端到端（End-to-End）的学习范式提取隐层状态并输出控制动作。这种范式虽然规避了人工特征工程的主观偏差，但高维视觉空间中充斥着大量与马尔可夫决策底层动力学无关的冗余信息（如光度变化、背景纹理差异、相机视角的微小偏移等）。由于卷积神经网络等视觉表征模块在联合优化时具有强烈的局部拟合倾向，模型极易将这些环境中的虚假关联（Spurious Correlations）作为决策依据。当测试阶段遭遇视觉要素的分布偏移时，泛化能力的缺失将直接导致策略崩溃。为了提升视觉强化学习在 OOD 环境下的鲁棒性，学术界广泛借鉴了计算机视觉领域的数据增强（Data Augmentation）技术，试图通过对训练样本施加随机平移、裁剪、色彩抖动或频率掩码等空间与光度变换，强行扩充观测分布的支撑集，从而迫使模型学习具备变换不变性（Transformation

Invariance）的泛化特征。

然而，从强化学习的理论推导角度审视，直接套用标准数据增强范式存在一个固有的理论矛盾：泛化能力的提升往往以牺牲样本利用效率（Sample Efficiency）与训练稳定性（Training Stability）为代价。与监督学习中分类标签对图像变换具有绝对不变性的假设不同，强化学习的核心优化目标是基于时间差分（Temporal Difference, TD）方法学习精确的状态-动作价值函数。时间差分自举（Bootstrapping）机制对状态序列的时间连续性与马尔可夫平滑性要求极高。当模型引入大尺度的数据增强操作（如剧烈的随机卷积或大角度旋转）时，不仅会破坏输入图像中原本具有严密几何意义的物理拓扑，更会导致相邻时间步的状态表征产生非平稳跳变。这种表征层面的高频震荡在贝尔曼更新（Bellman Update）过程中会被迅速放大，导致 TD 目标值的估计方差急剧攀升，进而引发策略梯度更新的发散。此外，部分增强类型在特定控制任务中具有内在的破坏性，例如盲目的旋转操作会直接摧毁状态空间中的方向语义，导致奖励信号与观测状态发生逻辑错位。因此，如何打破视觉强化学习中“泛化与稳定不可兼得”的困境，在引入数据多样性的同时有效抑制高方差 TD 误差的传播，迫切要求算法具备任务感知能力，能够从概率建模的视角自适应地筛选与当前任务动力学相适配的数据增强策略。这是当前视觉强化学习实现高效泛化亟待解决的表征优化难题。

与高维视觉输入所面临的冗余干扰挑战不同，离线强化学习（Offline RL）主要处理由一系列低维、结构化特征向量构成的状态空间。离线强化学习旨在完全脱离在线交互，仅依靠预先收集的静态次优数据集推演全局最优策略。当前主流的离线强化学习算法，如保守 Q 学习（CQL）与隐式 Q 学习（IQL），其核心理论贡献大多聚焦于解决动作空间的分布外（Action-space OOD）问题。这些方法通过向价值函数注入下界惩罚项，或采用非对称的期望回归（Expectile Regression）技术，有效限制了策略对未见动作的盲目查询，从而在数学上缓解了离线自举过程中的外推误差（Extrapolation Error）与值函数病态高估现象。

然而，现有离线强化学习算法的保守性约束往往仅局限于动作空间，其理论框架隐含了一个极为脆弱的前提：即测试阶段的状态边缘分布与离线训练数据集的状态分布严格对齐。在处理具有高度不确定性的复杂任务时，观测状态由于特征扰动或维度级数据缺失（Dimension-wise Missingness），极易发生严重的协变量偏移（Covariate Shift），进而产生状态空间的分布外（State-space OOD）难题。传统的离线强化学习模型通常采用多层感知机（MLP）拟合状态到动作的浅层非线性映射，这种参数化方式极其缺乏对状态变量内部固有相关性（如各个状态维度之间的运动学或动力学约束）的深度建模。当面临哪怕是单一维度特征缺失的 OOD 状态时，由于缺乏多模态特征推断与冗余信息对齐能力，神经网络的内部激活值会发生不可预期的剧烈偏移，产生严重的“特征坍塌（Feature Collapse）”现象。在特征坍塌效应的干扰下，原本受保守机制严格约束

的离线价值网络会陷入认知混淆，在 OOD 状态区域给出灾难性的价值高估，最终导致智能体策略失效。因此，面对状态空间的协变量偏移与特征缺失，如何引入深度的表征正则化（Representation Regularization）机制，促使模型挖掘状态空间固有的低维数据流形（Intrinsic Data Manifold），并通过表征层面的重构赋予智能体在异常残缺状态下的流形对齐与分布泛化能力，是离线强化学习领域尚未充分探索的核心理论盲区。

综合上述对高维视觉强化学习与低维离线强化学习在面对分布偏移时理论瓶颈的深度剖析，可以明确指出：无论是视觉空间中的冗余扰动，还是结构化状态空间中的特征缺失，其底层共性均揭示了当前强化学习算法在面对“不完美复杂观测”时，通用表示学习（Representation Learning）能力的严重匮乏。传统的强化学习优化范式过于侧重策略与价值网络后端的梯度计算设计，而长期忽视了在状态输入前端构建稳健、抗噪、具备推理能力的表征基础。

基于此背景，本文以提升强化学习在非平稳环境与观测分布偏移条件下的泛化能力与鲁棒性为总目标，重点围绕“面向复杂观测条件的强化学习表征优化与策略协同”展开系统性研究。本文的研究意义主要体现在理论拓展与算法设计两个维度：在理论研究层面，本文致力于打破传统强化学习端到端盲目联合优化的理论局限，深入探索表示学习辅助机制与强化学习策略优化过程的解耦与协同机制。针对视觉强化学习的高维观测 OOD 问题，本文提出基于任务感知的数据增强自适应选择机制，从概率论与信息瓶颈的角度揭示了增强数据分布、特征方差控制与任务奖励逻辑之间的深层关联。针对离线强化学习中的状态空间 OOD 与协变量偏移问题，本文首次将自监督掩码建模（Masked Modeling）思想引入低维连续状态空间，将掩码重构作为一种强大的表征正则化手段。在算法设计与应用潜力层面，本文的研究成果为提升人工智能算法在复杂不确定环境中的可靠性提供了切实可行的方法范式。

1.2 国内外研究现状

1.2.1 视觉强化学习与数据增强研究现状

在视觉强化学习中，智能体需要直接从高维像素空间中提取状态特征并进行决策。早期的视觉强化学习算法（如 DQN 及其变体）通常直接将卷积神经网络（CNN）与强化学习目标函数进行端到端联合训练。然而，受限于高维状态空间的复杂性与强化学习奖励信号的稀疏性，这类方法通常面临极低的样本效率。

为了提升视觉强化学习的数据利用率与特征提取能力，数据增强（Data Augmentation）技术被广泛引入。Laskin 等人（2020）提出了 RAD 框架，证明了简单的图像随机裁剪即可显著提升 Soft Actor-Critic (SAC) 算法的数据效率。Kostrikov 等人（2020）提出的 DrQ 算法，通过对同一观测图像进行多次随机平移增强，有效降低了目标 Q 值

的估计方差。随着强化学习应用场景的拓展，研究者开始关注视觉强化学习的分布外（OOD）泛化问题。Hansen 等人（2021）提出的 SVEA 算法深刻指出了强数据增强在强化学习中导致训练不稳定的原因，并修改了 Q 目标的形式以保持优化的稳定性。

尽管上述方法在提升泛化性能方面取得了显著进展，但它们普遍存在一个理论局限：忽视了数据增强类型与特定控制任务之间的语义适配性。现有的增强机制大多是盲目且独立于任务的（Task-Agnostic）。缺乏任务引导的强行增强，不可避免地会引入严重的观测噪声，导致样本效率的退化与策略训练的震荡。

1.2.2 离线强化学习与策略鲁棒性研究现状

离线强化学习（Offline RL）旨在从预先收集的静态数据集中学习策略。由于离线数据通常无法覆盖整个状态-动作空间，传统的异策略算法在离线设定下会产生严重的外推误差（Extrapolation Error）。为了克服这一难题，Kumar 等人（2020）提出的保守 Q 学习（CQL）通过引入 Q 值惩罚项学习保守的下界价值函数。Kostrikov 等人（2021）提出的隐式 Q 学习（IQL）则通过采用非对称的期望回归拟合状态价值函数 $V(s)$，极大地提升了离线强化学习在次优数据集上的表现。

然而，现有的离线强化学习算法普遍基于一个理想化前提：测试阶段的状态空间是完整且无损的。它们的“保守性”仅针对动作空间的 OOD 问题，而缺乏对状态空间分布偏移的抵御能力。在工业控制与机器人部署等真实场景中，更常见的问题是非对抗性的自然物理失效，例如因传感器老化或通信丢包导致的部分状态维度缺失。传统多层感知机（MLP）难以捕捉状态变量之间的潜在运动学或动力学约束。因此，如何为离线强化学习引入状态推断机制，提升其在传感器局部失效等破坏性状态下的特征恢复与策略鲁棒能力，是目前研究中尚未被充分填补的空白。

1.2.3 强化学习中的表示学习机制研究现状

为了应对高维冗余观测与部分信息缺失的挑战，将表示学习（Representation Learning）与强化学习相结合已成为近年的研究热点。Srinivas 等人（2020）提出的 CURL 算法成功将对比学习应用于基于像素的强化学习。在生成式掩码建模方面，受 MAE（He 等人, 2022）的启发，自监督的重建任务逐渐被引入决策序列建模。掩码建模通过随机掩码掉部分输入数据，迫使神经网络利用剩余的上下文信息进行还原，从而学习到数据内部深刻的结构依赖关系。

更重要的是，将自监督表示学习与强化学习的策略优化过程进行端到端联合训练，面临着严峻的梯度冲突（Gradient Conflict）问题。如果允许 TD 误差的梯度回传至特征编码器，会严重破坏重建任务原本提取的稳定物理结构特征，导致“表征坍塌”。因此，如何设计合理的架构，实现特征重建任务与策略优化任务的有效解耦（Decoupling），是

利用表示学习提升强化学习鲁棒性的关键技术挑战。

1.3 论文主要研究内容

本文聚焦于强化学习智能体在面临复杂观测环境时泛化能力不足与策略脆弱的核心难题。具体研究内容包括以下两个方面：

1） **针对视觉强化学习中因盲目应用数据增强导致的训练不稳定与样本低效问题，提出一种基于任务感知的数据增强选择方法（PICK）。**本文提出了一种任务感知型的数据增强选择框架（PICK）。首先，引入了一个独立并行的选择网络（Pick Network），动态输出不同数据增强方法在当前任务状态下被选用的概率分布。其次，利用 Critic 网络的目标函数反馈信号来指导选择网络的参数更新，使模型能够自适应地抑制具有破坏性的增强操作。实验结果表明，PICK 方法在样本利用效率、收敛速度以及未见环境的泛化性能方面均显著优于现有先进算法。

2） **针对离线强化学习中因传感器局部失效等物理信息缺失引发的特征坍塌与策略崩溃问题，提出一种基于自监督掩码重建的鲁棒离线强化学习方法（Masked-IQL）。**本文提出将自监督表示学习与离线强化学习相结合的 Masked-IQL 算法框架。首先，将传感器物理缺失建模为随机掩码（Masking）操作；其次，构建基于状态特征的掩码自编码器，通过最小化重建误差的辅助任务，迫使编码器挖掘不同维度传感器数据间潜在的物理约束关系。最后，设计了表征与决策严格解耦（Gradient Detach）的训练范式，成功避免了 TD 误差对重建流形的破坏。

1.4 论文组织结构

本文围绕复杂观测环境下的强化学习表征优化与鲁棒性问题展开系统性研究，全文共分为五章：

- **第一章绪论**：阐述研究背景及意义，梳理国内外研究现状，明确主要研究内容与组织结构。
- **第二章相关理论与技术**：介绍马尔可夫决策过程、SAC 算法、IQL 算法以及自监督表示学习理论。
- **第三章基于任务感知的视觉强化学习数据增强选择方法**：详细论述 PICK 算法的设计原理及其在视觉偏移环境下的优越性。
- **第四章基于自监督掩码重建的鲁棒离线强化学习方法**：阐述 Masked-IQL 算法在传感器局部失效条件下的鲁棒性与特征修复能力。
- **第五章总结与展望**：归纳创新点与贡献，并对未来研究方向进行展望。

2 相关理论与技术

2.1 强化学习与连续控制基础理论

强化学习（Reinforcement Learning, RL）是机器学习的重要分支，旨在研究智能体（Agent）如何通过与环境（Environment）的序贯交互，依据累积奖励信号逐步习得使长期回报最大化的最优决策策略。本节将系统阐述连续控制场景下强化学习的核心数学框架：首先定义马尔可夫决策过程及其在部分可观测情形下的扩展形式，继而从策略梯度定理出发推导 Actor-Critic 架构的理论依据，最后深入剖析最大熵强化学习框架及 Soft Actor-Critic 算法的核心机制，为后续章节的算法设计与表征优化提供理论基石。

2.1.1 马尔可夫决策过程与部分可观测马尔可夫决策过程

马尔可夫决策过程

强化学习问题的标准数学抽象为马尔可夫决策过程（Markov Decision Process, MDP）。一个完整的 MDP 由五元组 $\mathcal{M} = \langle \mathcal{S}, \mathcal{A}, \mathcal{P}, \mathcal{R}, \gamma \rangle$ 严格定义，各分量含义如下：

- $\mathcal{S}$ 为状态空间（State Space），表示环境中所有可能状态的集合。在连续控制任务中，$\mathcal{S} \subseteq \mathbb{R}^n$ 通常为高维连续空间，描述系统的完整物理配置（如关节角度、速度、接触力等）。
- $\mathcal{A}$ 为动作空间（Action Space），表示智能体可执行动作的集合。连续控制任务中，$\mathcal{A} \subseteq \mathbb{R}^m$ 为连续向量空间，对应电机力矩或关节速度等控制指令。
- $\mathcal{P} : \mathcal{S} \times \mathcal{A} \times \mathcal{S} \to [0, 1]$ 为状态转移概率函数，$\mathcal{P}(s' \mid s, a)$ 描述智能体在状态 $s \in \mathcal{S}$ 执行动作 $a \in \mathcal{A}$ 后转移至状态 $s' \in \mathcal{S}$ 的概率，刻画了环境的随机动力学特性。
- $\mathcal{R} : \mathcal{S} \times \mathcal{A} \to \mathbb{R}$ 为奖励函数，$r(s, a) = \mathcal{R}(s, a)$ 定义了智能体在状态 s 下执行动作 a 所获得的即时标量反馈，是引导策略优化的核心信号。
- $\gamma \in [0, 1)$ 为折扣因子（Discount Factor），用于权衡未来奖励与即时奖励的相对重要性，同时确保无限时域下累积回报的数学收敛性。

MDP 的核心假设为马尔可夫性质（Markov Property）：系统下一状态的条件概率分布仅依赖于当前状态与动作，而与历史轨迹无关，即

$$\mathcal{P}(s_{t+1} \mid s_t, a_t, s_{t-1}, a_{t-1}, \ldots, s_0, a_0) = \mathcal{P}(s_{t+1} \mid s_t, a_t) \tag{2-1}$$

在每一时间步 t，智能体观测到当前状态 s_t，依据策略 $\pi : \mathcal{S} \to \Delta(\mathcal{A})$ 选择动作 $a_t \sim \pi(\cdot \mid s_t)$（其中 $\Delta(\mathcal{A})$ 表示 $\mathcal{A}$ 上的概率单纯形），环境转移至新状态 $s_{t+1} \sim \mathcal{P}(\cdot \mid s_t, a_t)$ 并产生即时奖励 $r_t = r(s_t, a_t)$。智能体的优化目标是寻找最优策略 π^*，使得折扣累积期

望回报最大化：

$$J(\pi) = \mathbb{E}_{\tau\sim\pi}\left[\sum_{t=0}^{\infty}\gamma^t r(s_t, a_t)\right] \tag{2-2}$$

其中，$\tau = (s_0, a_0, s_1, a_1, \ldots)$ 为策略 π 与环境交互产生的轨迹（Trajectory）。

为评估策略的优劣，定义状态价值函数（State Value Function）$V^\pi : \mathcal{S} \to \mathbb{R}$ 与动作价值函数（Action-Value Function）$Q^\pi : \mathcal{S} \times \mathcal{A} \to \mathbb{R}$：

$$V^\pi(s) = \mathbb{E}_\pi\left[\sum_{k=0}^{\infty}\gamma^k r_{t+k} \,\middle|\, s_t = s\right] \tag{2-3}$$

$$Q^\pi(s, a) = \mathbb{E}_\pi\left[\sum_{k=0}^{\infty}\gamma^k r_{t+k} \,\middle|\, s_t = s,\ a_t = a\right] \tag{2-4}$$

两者之间满足 $V^\pi(s) = \mathbb{E}_{a\sim\pi(\cdot|s)}[Q^\pi(s, a)]$。根据动态规划原理，$Q^\pi$ 满足贝尔曼期望方程（Bellman Expectation Equation）：

$$Q^\pi(s, a) = \mathbb{E}_{s'\sim\mathcal{P}(\cdot|s,a)}\left[r(s, a) + \gamma\mathbb{E}_{a'\sim\pi(\cdot|s')}\left[Q^\pi(s', a')\right]\right] \tag{2-5}$$

此递归关系构成了基于时序差分（Temporal Difference, TD）学习的理论基础，同时也是 Critic 网络参数更新的核心依据。

部分可观测马尔可夫决策过程

标准 MDP 假设智能体在每一时间步均可精确获得系统的完整状态 s_t。然而，在大量现实控制场景中，智能体仅能获取原始传感器数据（如图像像素、激光雷达点云或局部关节读数），这些数据往往只是真实系统状态的不完整投影，且可能包含噪声。此类场景更为精确的数学描述为部分可观测马尔可夫决策过程（Partially Observable Markov Decision Process, POMDP），由七元组 $\mathcal{M}_{\text{po}} = \langle\mathcal{S}, \mathcal{A}, \mathcal{P}, \mathcal{R}, \Omega, \mathcal{O}, \gamma\rangle$ 定义，其中 Ω 为观测空间（Observation Space），$\mathcal{O} : \mathcal{S} \times \mathcal{A} \to \Delta(\Omega)$ 为观测概率函数，$\mathcal{O}(o \mid s', a)$ 表示智能体执行动作 a 并转移至状态 s' 后获得观测 $o \in \Omega$ 的概率。

在 POMDP 中，观测 o_t 与状态 s_t 的本质区别在于：s_t 包含完整刻画系统动力学所需的全部信息，而 o_t 仅为 s_t 的一个条件采样，即

$$o_t \sim \mathcal{O}(\cdot \mid s_t, a_{t-1}) \tag{2-6}$$

由于 o_t 无法唯一确定 s_t，智能体必须依赖历史交互序列 $h_t = (o_0, a_0, o_1, a_1, \ldots, o_t)$ 来推断状态的后验分布。这一推断在数学上以信念状态（Belief State）$b_t \in \Delta(\mathcal{S})$ 表示：

$$b_t(s) = \mathcal{P}(s_t = s \mid h_t) \tag{2-7}$$

信念状态依据贝叶斯滤波（Bayesian Filtering）递归更新：

$$b_{t+1}(s') = \eta \cdot \mathcal{O}(o_{t+1} \mid s', a_t) \sum_{s \in \mathcal{S}} \mathcal{P}(s' \mid s, a_t)\, b_t(s) \tag{2-8}$$

其中，η 为归一化常数，确保 b_{t+1} 在状态空间上积分为 1。

以基于图像的视觉控制任务为例，真实状态 s_t 包含机器人的完整关节配置与速度信息，而智能体仅能获取 RGB 图像 $o_t \in \mathbb{R}^{H \times W \times 3}$。单帧图像不仅无法反映速度等动态量，还可能受到遮挡、光照变化与传感器噪声的影响。这一" 状态不确定性"（State Uncertainty）使得直接将 o_t 代入为 MDP 中的 s_t 存在根本性的理论缺陷：策略 $\pi(a \mid o_t)$ 所依赖的信息量不足以满足马尔可夫性质，进而导致值函数估计的系统性偏差与策略收敛性能的下降。

上述分析表明，在部分可观测场景下，有效的状态表征（State Representation）是算法性能的关键瓶颈：一方面，需要从高维观测中提取紧凑而充分的特征；另一方面，需要跨时间步聚合历史信息以近似马尔可夫状态。这一内在需求为后文引入自监督表示学习与序列建模技术提供了直接的理论动机。

2.1.2 Actor-Critic 架构

Actor-Critic 架构是连续动作空间控制任务中最为主流的深度强化学习范式之一。其理论基础源于策略梯度定理（Policy Gradient Theorem），通过将策略优化（Actor）与值函数估计（Critic）相解耦，在保留策略梯度方法灵活性的同时，系统性地降低了梯度估计的方差。

策略梯度定理

设参数化随机策略为 $\pi_\theta(a \mid s)$，其中 θ 为可学习参数。策略的优化目标为最大化期望回报：

$$J(\theta) = \mathbb{E}_{\tau \sim \pi_\theta}\left[\sum_{t=0}^{\infty} \gamma^t r(s_t, a_t)\right] = \mathbb{E}_{s \sim d^{\pi_\theta}}\left[V^{\pi_\theta}(s)\right] \tag{2-9}$$

其中，$d^{\pi_\theta}(s) = \sum_{t=0}^{\infty} \gamma^t \mathcal{P}(s_t = s \mid \pi_\theta)$ 为策略 π_θ 诱导的折扣状态访问分布（Discounted State Visitation Distribution）。

策略梯度定理给出了目标函数关于策略参数的解析梯度形式。利用对数导数技巧（Log-Derivative Trick）展开，并结合贝尔曼方程递归代入，可严格推导得：

$$\nabla_\theta J(\theta) = \mathbb{E}_{s \sim d^{\pi_\theta},\, a \sim \pi_\theta(\cdot \mid s)}\left[\nabla_\theta \log \pi_\theta(a \mid s) \cdot Q^{\pi_\theta}(s, a)\right] \tag{2-10}$$

此公式的核心意义在于：无需对环境动力学 $\mathcal{P}$ 求导，梯度仅通过对策略的微分即可获得，从而使得策略梯度方法在模型未知的情形下依然适用。

基线方差缩减与优势函数

直接使用 $Q^{\pi_\theta}(s,a)$ 作为梯度权重的 REINFORCE 算法，尽管在期望意义下无偏，但 Q 值的绝对量级差异较大，导致梯度估计具有极高方差，使训练不稳定。策略梯度定理允许在不改变梯度期望值的前提下，引入任意与动作 a 无关的基线函数 $b(s)$：

$$\nabla_\theta J(\theta) = \mathbb{E}_{s\sim d^{\pi_\theta},\, a\sim\pi_\theta(\cdot|s)}\left[\nabla_\theta \log \pi_\theta(a \mid s)\cdot\left(Q^{\pi_\theta}(s,a) - b(s)\right)\right] \tag{2-11}$$

基线不改变梯度期望的无偏性由下式保证：

$$\mathbb{E}_{a\sim\pi_\theta(\cdot|s)}\left[\nabla_\theta \log \pi_\theta(a \mid s)\cdot b(s)\right] = b(s)\,\nabla_\theta \underbrace{\sum_a \pi_\theta(a \mid s)}_{=1} = 0 \tag{2-12}$$

选取 $b(s) = V^{\pi_\theta}(s)$ 可将梯度方差缩减至接近理论下界。此时，梯度权重退化为优势函数（Advantage Function）：

$$A^{\pi_\theta}(s,a) = Q^{\pi_\theta}(s,a) - V^{\pi_\theta}(s) \tag{2-13}$$

$A^{\pi_\theta}(s,a)$ 的物理含义为：在状态 s 下执行动作 a 相较于当前策略的平均水平所带来的额外收益。当 $A > 0$ 时，该动作优于平均，策略应增大其选择概率；当 $A < 0$ 时，策略应降低其概率，从而实现精确的信用分配（Credit Assignment）。

Actor-Critic 的双网络协同优化

Actor-Critic 架构通过引入两个独立的参数化网络，将策略优化与值函数估计解耦：

- **Actor 网络** $\pi_\theta(a \mid s)$：参数化随机策略，负责生成动作。在连续控制中，通常输出高斯分布的均值 $\mu_\theta(s)$ 与标准差 $\sigma_\theta(s)$，即 $a \sim \mathcal{N}(\mu_\theta(s), \sigma_\theta^2(s)\mathbf{I})$。
- **Critic 网络** $V_\varphi(s)$ 或 $Q_\varphi(s,a)$：参数化值函数，负责估计当前策略的回报预期，为 Actor 提供低方差的梯度信号。

Critic 通过最小化时序差分误差进行参数更新，以单步 TD 为例，其损失函数定义为：

$$L_{\text{critic}}(\varphi) = \mathbb{E}_{(s_t,a_t,r_t,s_{t+1})\sim\mathcal{D}}\left[\left(V_\varphi(s_t) - \left(r_t + \gamma V_{\bar{\varphi}}(s_{t+1})\right)\right)^2\right] \tag{2-14}$$

其中，$V_{\bar{\varphi}}$ 表示目标网络（Target Network），其参数通过指数移动平均缓慢跟踪 φ，以稳定自举（Bootstrapping）过程。Actor 利用 Critic 估计的优势函数执行策略梯度更新：

$$\nabla_\theta J(\theta) \approx \mathbb{E}_{(s_t,a_t)\sim\mathcal{D}}\left[\nabla_\theta \log \pi_\theta(a_t \mid s_t) \cdot \hat{A}(s_t, a_t)\right] \tag{2-15}$$

其中，$\hat{A}(s_t, a_t) = r_t + \gamma V_{\bar{\varphi}}(s_{t+1}) - V_\varphi(s_t)$ 为 TD 残差对优势函数的单步估计。

Actor-Critic 架构的本质贡献在于将高方差的蒙特卡洛回报估计替换为低方差的自举估计，在样本效率与估计精度之间取得有效平衡。然而，该架构中 Critic 网络的估计质量直接制约着 Actor 梯度信号的可靠性：若 Critic 基于不充分的状态表征进行值函数估计，则梯度偏差将直接损害策略的收敛性能。这一依赖关系深刻揭示了表征质量对整体算法性能的核心影响。

2.1.3 最大熵强化学习与 Soft Actor-Critic 算法

最大熵强化学习目标

标准强化学习仅优化期望累积回报，当策略趋于确定性时，智能体的探索能力随之退化，极易陷入局部最优。最大熵强化学习（Maximum Entropy Reinforcement Learning）在优化目标中引入策略熵正则项，将目标函数修正为：

$$J_{\text{MaxEnt}}(\pi) = \sum_{t=0}^{T} \mathbb{E}_{(s_t,a_t)\sim\rho_\pi}\left[r(s_t, a_t) + \alpha\mathcal{H}(\pi(\cdot \mid s_t))\right] \tag{2-16}$$

其中，$\mathcal{H}(\pi(\cdot \mid s_t)) = -\mathbb{E}_{a\sim\pi(\cdot|s_t)}[\log \pi(a \mid s_t)]$ 为策略在状态 s_t 下的香农熵（Shannon Entropy），$\rho_\pi(s_t, a_t)$ 为策略 π 诱导的状态-动作边际分布，$\alpha > 0$ 为温度参数（Temperature Parameter），控制熵正则化的强度。将期望展开，目标函数等价地表示为：

$$J_{\text{MaxEnt}}(\pi) = \sum_{t=0}^{T} \mathbb{E}_{(s_t,a_t)\sim\rho_\pi}\left[r(s_t, a_t) - \alpha \log \pi(a_t \mid s_t)\right] \tag{2-17}$$

熵正则项的引入在理论上具有三重效应：其一，迫使策略在等效动作之间保持均匀分布，增强探索多样性；其二，使策略对奖励函数的微小扰动具有更强的鲁棒性；其三，为多峰奖励景观中的策略表示提供了自然的概率框架，有效防止策略过早收敛至次优确定性解。

软贝尔曼方程

在最大熵框架下，定义软状态价值函数（Soft State Value Function）V^π_{soft} 与软动作价值函数（Soft Q-Function）Q^π_{soft}：

$$V^\pi_{\text{soft}}(s_t) = \mathbb{E}_{a\sim\pi(\cdot|s_t)}\left[Q^\pi_{\text{soft}}(s_t, a) - \alpha \log \pi(a \mid s_t)\right] \tag{2-18}$$

$$Q^\pi_{\text{soft}}(s_t, a_t) = r(s_t, a_t) + \gamma\, \mathbb{E}_{s_{t+1}\sim\mathcal{P}}\left[V^\pi_{\text{soft}}(s_{t+1})\right] \tag{2-19}$$

将两式联立，得到软 Q 函数所满足的软贝尔曼期望方程（Soft Bellman Expectation Equation）：

$$Q^{\pi}_{\text{soft}}(s_t, a_t) = r(s_t, a_t) + \gamma\, \mathbb{E}_{\substack{s_{t+1}\sim\mathcal{P} \\ a_{t+1}\sim\pi}}\Big[Q^{\pi}_{\text{soft}}(s_{t+1}, a_{t+1}) - \alpha \log \pi(a_{t+1} \mid s_{t+1})\Big] \tag{2-20}$$

与标准贝尔曼方程相比，软贝尔曼方程在目标值中额外纳入了策略熵项，使得 Q 值在反映动作回报潜力的同时，亦对策略的随机性给予额外奖励。

SAC 算法的参数化与损失函数

Soft Actor-Critic（SAC）算法[haarnoja2018soft]将最大熵强化学习框架与离策略（Off-Policy）深度学习相结合，通过维护两个 Critic 网络、一个 Actor 网络与对应的目标网络实现高效稳定的连续控制。

Critic 损失函数：SAC 采用双 Q 网络（Double Q-Network）结构以缓解值函数高估问题。参数分别为 θ_1 和 θ_2 的两个 Critic 网络的训练目标定义为：

$$L_Q(\theta_i) = \mathbb{E}_{(s_t, a_t, r_t, s_{t+1})\sim\mathcal{D}}\left[\left(Q_{\theta_i}(s_t, a_t) - y_t\right)^2\right], \quad i \in \{1, 2\} \tag{2-21}$$

其中，TD 目标 y_t 由目标网络（参数分别为 $\bar{\theta}_1$，$\bar{\theta}_2$）与当前策略联合确定：

$$y_t = r_t + \gamma\left(\min_{j\in\{1,2\}} Q_{\bar{\theta}_j}(s_{t+1}, \tilde{a}_{t+1}) - \alpha \log \pi_{\varphi}(\tilde{a}_{t+1} \mid s_{t+1})\right), \quad \tilde{a}_{t+1} \sim \pi_{\varphi}(\cdot \mid s_{t+1}) \tag{2-22}$$

取两个目标网络 Q 值之最小值，有效抑制了函数逼近误差的累积传播，提升了 Critic 估计的保守性与训练稳定性。

Actor 损失函数：为使 Actor 能够在连续动作空间中进行梯度优化，SAC 采用重参数化技巧（Reparameterization Trick）。将动作 $\tilde{a}$ 表示为噪声变量 ϵ 的确定性函数 $\tilde{a}_t = f_{\varphi}(\epsilon_t; s_t)$，其中 $\epsilon_t \sim \mathcal{N}(0, \mathbf{I})$，$f_{\varphi}$ 通常取压缩变换：

$$\tilde{a}_t = \tanh\Big(\mu_{\varphi}(s_t) + \sigma_{\varphi}(s_t) \odot \epsilon_t\Big) \tag{2-23}$$

Actor 的训练目标为最小化以下损失：

$$L_{\pi}(\varphi) = \mathbb{E}_{s_t\sim\mathcal{D},\, \epsilon_t\sim\mathcal{N}}\left[\alpha \log \pi_{\varphi}\Big(f_{\varphi}(\epsilon_t; s_t) \mid s_t\Big) - \min_{j\in\{1,2\}} Q_{\theta_j}\Big(s_t, f_{\varphi}(\epsilon_t; s_t)\Big)\right] \tag{2-24}$$

通过重参数化，梯度可以直接从 Q 网络反向传播至 Actor 参数 φ，将高方差的策略梯度估计转化为低方差的路径梯度估计，从而显著提升优化效率。

温度参数自适应调节：SAC 将温度参数 α 视为可学习变量，通过最小化以下目标

自动确定其值：

$$L(\alpha) = \mathbb{E}_{a_t \sim \pi_\varphi(\cdot|s_t)} \left[-\alpha \log \pi_\varphi(a_t \mid s_t) - \alpha \bar{\mathcal{H}} \right] \tag{2-25}$$

其中，$\bar{\mathcal{H}}$ 为预设的目标熵，通常设为 $\bar{\mathcal{H}} = -\dim(\mathcal{A})$。当当前策略熵低于 $\bar{\mathcal{H}}$ 时，α 自动增大以加强探索；反之则减小以强化利用，实现了探索-利用权衡的动态自适应调节。

探索与利用权衡的数学本质

SAC 在探索-利用权衡（Exploration-Exploitation Trade-off）上的优越性，源自最大熵目标对最优策略解的结构性约束。可以证明，在最大熵框架下，最优软策略具有如下闭合形式：

$$\pi^*_{\text{soft}}(a \mid s) \propto \exp\left(\frac{1}{\alpha} Q^*_{\text{soft}}(s, a) \right) \tag{2-26}$$

此结论表明，最优软策略本质上是软 Q 值的玻尔兹曼分布（Boltzmann Distribution）。当 $\alpha \to 0$ 时，策略退化为确定性贪婪策略，对应纯利用；当 $\alpha \to \infty$ 时，策略趋于均匀分布，对应纯探索。温度参数 α 在两极端之间连续插值，提供了比 ϵ-贪婪等启发式方法更为严格的数学基础，并赋予探索行为以明确的信息论意义。

综上所述，SAC 通过最大熵目标、双 Q 网络估计与重参数化策略梯度的协同设计，在连续控制任务中实现了样本效率与训练稳定性的显著提升。然而，上述所有机制均建立在 Critic 和 Actor 网络能够从输入观测中提取高质量状态表征这一前提之上。在部分可观测场景下，若观测 o_t 与真实状态 s_t 之间存在较大的信息鸿沟，则值函数估计的精度与策略梯度的可靠性均将受到根本性制约。如何从高维、噪声观测中构建紧凑而充分的潜在状态表征，是提升上述算法在复杂视觉控制任务中性能的核心问题，这也正是本文后续章节所要深入探讨的主旨所在。

2.2 离线强化学习与保守价值评估

在线强化学习（Online RL）要求智能体与环境持续交互以收集训练数据，然而在众多现实场景中——例如医疗决策、自动驾驶或机器人操作——此类交互的代价极为高昂甚至存在安全风险。离线强化学习范式的提出，旨在仅利用历史数据驱动策略学习，彻底规避在线交互的代价。然而，这一范式转换带来了标准强化学习框架所不具备的核心理论难题：分布偏移与外推误差。本节将系统阐述上述问题的数学本质，并深入剖析以隐式 Q 学习为代表的保守价值评估方法如何在理论层面予以解决。

2.2.1 离线强化学习范式与分布偏移问题

离线强化学习的基本范式

离线强化学习（Offline Reinforcement Learning）的核心约束在于：学习过程中智能

体无法与环境产生任何新的交互，策略优化所依赖的全部信息来源于一个预先收集的静态数据集：

$$\mathcal{D} = \left\{ \left(s_t^{(i)},\, a_t^{(i)},\, r_t^{(i)},\, s_{t+1}^{(i)} \right) \right\}_{i=1}^{N} \tag{2-27}$$

该数据集由一个或多个行为策略（Behavior Policy）π_β 与环境交互产生，π_β 可以是人类专家、启发式控制器、次优在线智能体或上述多者的混合。数据集中的状态-动作对服从行为策略诱导的分布 $\rho^{\mathcal{D}}(s,a) = d^{\pi_\beta}(s)\,\pi_\beta(a \mid s)$，其中 $d^{\pi_\beta}(s)$ 为 π_β 的折扣状态访问分布。

在此约束下，离线强化学习的目标等价于：在 $\mathcal{D}$ 的支撑范围内寻找能够最大化真实环境回报的策略 π，而不依赖于额外的环境反馈。

分布偏移的数学表征

分布偏移（Distribution Shift）是离线强化学习区别于在线学习的根本性挑战。其核心矛盾在于：学习得到的策略 π 在部署阶段所访问的状态-动作分布 $\rho^{\pi}(s,a) = d^{\pi}(s)\,\pi(a \mid s)$，与数据集所反映的分布 $\rho^{\mathcal{D}}(s,a)$ 之间存在结构性差异。

具体地，将两者之间的分布偏移量化为全变差（Total Variation）距离或 KL 散度：

$$D_{\mathrm{TV}}\left(\rho^{\pi} \,\|\, \rho^{\mathcal{D}}\right) = \frac{1}{2} \int_{\mathcal{S}\times\mathcal{A}} \left| \rho^{\pi}(s,a) - \rho^{\mathcal{D}}(s,a) \right| \mathrm{d}s\,\mathrm{d}a \tag{2-28}$$

当 π 偏离 π_β 时，ρ^{π} 将在 $\mathcal{D}$ 未充分覆盖的区域赋予显著概率质量。正是在这些分布外（Out-of-Distribution, OOD）区域，Q 函数的泛化行为无法由数据监督，从而引发估计失真。

外推误差的逻辑链及其灾难性后果

将分布偏移导致值函数失效的过程形式化为以下推导链。

标准离线 Q 学习的贝尔曼更新为：

$$Q_\theta(s,a) \leftarrow r(s,a) + \gamma \max_{a' \in \mathcal{A}} Q_{\bar{\theta}}(s',a') \tag{2-29}$$

其中 $Q_{\bar{\theta}}$ 为目标网络。注意，上式中的 $\max_{a'}$ 算子在整个动作空间 $\mathcal{A}$ 上取最大，而非仅在数据集支撑 $\mathrm{supp}(\pi_\beta(\cdot \mid s'))$ 上取最大。

设 $a^*_{s'} = \arg\max_{a'} Q_{\bar{\theta}}(s',a')$ 为所选择的贪婪动作，当 $a^*_{s'} \notin \mathrm{supp}(\pi_\beta(\cdot \mid s'))$ 时，即 $a^*_{s'}$ 为分布外动作，神经网络函数逼近器对其 Q 值的估计完全依赖于在分布内数据上学到的归纳偏置（Inductive Bias）的外推，缺乏任何真实环境反馈的约束。

定义外推误差为：

$$\epsilon_{\text{extrap}}(s,a) \triangleq |Q_\theta(s,a) - Q^{\pi_\beta}(s,a)|, \quad (s,a) \notin \text{supp}(\mathcal{D}) \tag{2-30}$$

由于神经网络倾向于对分布外输入输出异常大的激活值，Q_θ 在 OOD 区域通常呈现严重的高估（Overestimation Bias）。更为致命的是，这一误差通过贝尔曼自举（Bellman Bootstrapping）的递归传播机制扩散至分布内的状态-动作对。设第 k 次迭代后的误差上界为 ϵ_k，则有如下误差传播不等式：

$$\epsilon_{k+1} \leq \gamma\epsilon_k + \gamma \cdot \epsilon_{\text{extrap}} \tag{2-31}$$

该递推关系表明，外推误差以几何级数向历史状态-动作对反向传播，在迭代过程中造成系统性的 Q 值虚高。策略 π 在此虚高 Q 值指引下倾向于选择 OOD 动作（因其 Q 值估计最大），而这些动作在真实环境中的回报往往远低于预期，最终导致训练完成后策略性能严重下降甚至彻底失效。

上述分析揭示，离线 Q 学习的失效根源并非算法设计的缺陷，而是函数逼近与分布偏移在贝尔曼自举框架下的结构性冲突。有效的解决方案须从根本上消除或约束对 OOD 动作 Q 值的依赖，这正是以 IQL 为代表的保守价值评估方法的理论出发点。

2.2.2 隐式 Q 学习算法

理论初衷：消除分布外动作查询

隐式 Q 学习（Implicit Q-Learning, IQL）**kostrikov2021offline**的核心理论贡献在于，提出了一种完全规避对分布外动作进行显式 Q 值查询的价值评估范式。其关键洞察在于：贝尔曼最优算子中的 $\max_{a'} Q(s',a')$ 操作并非不可替代——若能直接估计数据集支撑范围内的最优状态价值函数 $V(s')$，则该项可以被安全地替换为 $V(s')$，从而在 TD 目标的计算中完全消除对具体动作的依赖。

然而，直接从数据集中估计 $V^*(s) = \max_{a\in\text{supp}(\pi_\beta(\cdot|s))} Q^*(s,a)$ 面临如下困难：数据集中对于给定状态 s，动作的采样密度有限，简单取最大值将导致严重的有限样本偏差（Finite-Sample Bias）。IQL 通过期望回归（Expectile Regression）提供了这一问题的严格统计解。

期望回归的数学推导

设随机变量 X 服从分布 $\mathcal{P}_X$，对于给定的期望水平 $\tau \in (0,1)$，X 的 τ-期望值（τ-Expectile）定义为以下优化问题的解：

$$m_\tau = \arg\min_{m\in\mathbb{R}} \ \mathbb{E}_{X\sim\mathcal{P}_X}[\mathcal{L}_2^\tau(X-m)] \tag{2-32}$$

其中，非对称平方损失函数（Asymmetric Squared Loss）$\mathcal{L}_2^\tau : \mathbb{R} \to \mathbb{R}_{\geq 0}$ 定义为：

$$\mathcal{L}_2^\tau(u) = |\tau - \mathbb{I}(u < 0)|\, u^2 \tag{2-33}$$

式中，$\mathbb{I}(\cdot)$ 为指示函数（Indicator Function）。展开可得：

$$\mathcal{L}_2^\tau(u) = \begin{cases} \tau\, u^2, & u \geq 0 \\ (1-\tau)\, u^2, & u < 0 \end{cases} \tag{2-34}$$

对期望取一阶最优性条件，令 $\frac{\partial}{\partial m}\mathbb{E}[\mathcal{L}_2^\tau(X-m)] = 0$，得：

$$2\tau\, \mathbb{E}[(X-m)\, \mathbb{I}(X \geq m)] - 2(1-\tau)\, \mathbb{E}[(X-m)\, \mathbb{I}(X < m)] = 0 \tag{2-35}$$

分析上式关于 τ 的极端情形：

- 当 $\tau = 0.5$ 时，损失函数退化为标准均方误差，$m_{0.5}$ 为分布 $\mathcal{P}_X$ 的均值 $\mathbb{E}[X]$。
- 当 $\tau \to 1$ 时，正残差 $(X-m)$ 所受惩罚趋向无穷大，迫使 m 趋近于 X 的支撑上确界，即 $m_\tau \to \operatorname{ess\,sup} X$。
- 当 $\tau \in (0.5, 1)$ 时，m_τ 为均值与上确界之间关于 τ 单调递增的插值，即分布的高分位数估计。

这一性质表明，通过选取较大的 τ 值（如 $\tau = 0.7 \sim 0.9$），期望回归可以在统计意义上稳健地逼近分布的上端，从而隐式实现对策略价值上界的估计。

IQL 的三阶段训练机制

IQL 将价值估计解耦为三个独立的监督学习目标，各阶段均严格约束在数据集分布内。

<u>第一阶段——状态价值函数的期望回归训练</u>：利用期望回归训练参数为 ψ 的状态价值网络 $V_\psi(s)$，其损失函数为：

$$L_V(\psi) = \mathbb{E}_{(s,a)\sim\mathcal{D}}\Big[\mathcal{L}_2^\tau\Big(Q_{\bar{\theta}}(s,a) - V_\psi(s)\Big)\Big] \tag{2-36}$$

其中，$Q_{\bar{\theta}}$ 为目标 Q 网络（参数 $\bar{\theta}$ 为 θ 的指数移动平均）。$V_\psi(s)$ 的物理意义得以精确刻画：它并非在整个动作空间上的期望或最大值，而是在给定状态 s 下，数据集所记录的 Q 值分布 $\{Q_{\bar{\theta}}(s,a) : (s,a) \in \mathcal{D}\}$ 的 τ-期望值——即数据集支撑范围内的高分位价值估计。由于 $V_\psi(s)$ 的优化目标仅涉及数据集中已有的 (s,a) 对，整个过程完全不查询任何分布外动作的 Q 值。

第二阶段——Q 函数的保守贝尔曼更新：利用第一阶段学得的 V_ψ 替代标准贝尔曼算子中的 $\max_{a'} Q(s', a')$，对参数为 θ 的 Q 网络执行保守的 TD 更新：

$$L_Q(\theta) = \mathbb{E}_{(s,a,r,s')\sim\mathcal{D}}\left[\left(Q_\theta(s,a) - \underbrace{\left(r + \gamma V_\psi(s')\right)}_{\text{无动作查询的 TD 目标}}\right)^2\right] \tag{2-37}$$

TD 目标 $r + \gamma V_\psi(s')$ 在计算中无需指定动作 a'，完全规避了对 s' 处任何具体动作 Q 值的查询，从根本上切断了外推误差的传播路径。

第三阶段——优势加权回归策略提取：利用前两阶段的估计结果，通过优势加权回归（Advantage Weighted Regression, AWR）[peng2019advantage]从数据集中提取策略 π_φ：

$$L_\pi(\varphi) = -\mathbb{E}_{(s,a)\sim\mathcal{D}}\Big[\exp(\beta \cdot A(s,a)) \cdot \log \pi_\varphi(a \mid s)\Big] \tag{2-38}$$

其中，优势函数 $A(s,a) = Q_{\bar\theta}(s,a) - V_\psi(s)$ 衡量数据集中动作 a 相对于当前 V_ψ 估计值的超额回报，$\beta > 0$ 为逆温度参数。

AWR 目标的等价形式为加权最大似然估计：

$$L_\pi(\varphi) = -\mathbb{E}_{(s,a)\sim\mathcal{D}}\Big[w(s,a) \cdot \log \pi_\varphi(a \mid s)\Big], \quad w(s,a) = \exp\Big(\beta\big(Q_{\bar\theta}(s,a) - V_\psi(s)\big)\Big) \tag{2-39}$$

权重 $w(s,a)$ 对优势为正的动作（即优于当前值函数估计的动作）赋予指数级放大的模仿权重，对优势为负的动作赋予接近零的权重，从而在纯行为克隆（Behavioral Cloning）与纯策略优化之间取得原则性权衡。通过参数 β 的调节，IQL 可以在” 保守地模仿数据集” 与” 激进地提取数据集最优行为” 之间灵活权衡，而整个提取过程始终限制在数据集的动作分布支撑范围内，有效规避了分布外泛化的风险。

IQL 的理论一致性

IQL 的三阶段设计具有严格的理论一致性保证。当数据集覆盖充分（$\mathcal{D}$ 包含最优策略的支撑）且 $\tau \to 1$ 时，$V_\psi(s)$ 在统计意义上趋近于 $\max_{a\in\mathrm{supp}(\pi_\beta(\cdot|s))} Q^*(s,a)$，Q 网络的 TD 更新趋近于贝尔曼最优算子，AWR 策略提取趋近于最优策略。在 $\tau < 1$ 的一般情形下，IQL 提供了一个关于 τ 连续参数化的保守性-最优性权衡谱系，为实践中针对数据集质量的自适应调节提供了理论依据。

综上所述，IQL 通过将最优价值评估问题转化为期望回归——一种严格约束于数据集分布的统计估计任务——从根本上消除了离线 Q 学习对分布外动作查询的依赖，并借助优势加权回归实现了稳健而高效的策略提取。这一价值评估范式的转变表明：在复杂观测场景下，高质量的状态表征对于准确估计 $Q_{\bar\theta}(s,a)$ 与 $V_\psi(s)$ 同等关键——若状

态编码器无法从高维噪声观测中提取充分的语义特征，则期望回归所估计的 τ-期望值将因输入信息不充分而产生系统性偏差，进而损害策略提取的质量。这一理论分析为后文在复杂残缺观测环境下进一步优化特征表征的研究路径提供了明确的方法论基础。

2.3 复杂观测下的表示学习机制

前两节分别从决策框架与价值评估角度建立了强化学习的理论基础。然而，上述框架均隐含一个前提：智能体能够从原始观测中获取足以支撑精确价值估计的状态信息。当观测为高维图像或存在结构性缺失时，这一前提不再自然成立，表征学习的质量成为制约整体性能的关键瓶颈。本节从两个互补维度剖析复杂观测场景下的表征构建机制：其一，基于数据增强的视觉不变性表征；其二，基于掩码建模的低维物理状态重构。两者共同构成本文核心算法设计的表征理论基础。

2.3.1 视觉强化学习与数据增强表示

卷积神经网络的降维表征作用

基于图像的视觉强化学习（Visual Reinforcement Learning）面临的首要挑战是维度灾难（Curse of Dimensionality）：原始 RGB 观测 $o_t \in \mathbb{R}^{H\times W\times C}$ 的像素空间维度通常达到 $10^4 \sim 10^5$ 量级，而真正决定系统动力学的物理自由度（关节角、速度、接触力等）往往仅有数十维。卷积神经网络（Convolutional Neural Network, CNN）凭借局部感受野与参数共享的归纳偏置，对视觉观测实施层次化的非线性特征提取：

$$z_t = E_\varphi(o_t), \quad E_\varphi : \mathbb{R}^{H\times W\times C} \to \mathbb{R}^d, \quad d \ll H\cdot W\cdot C \tag{2-40}$$

其中，E_φ 为参数化的 CNN 编码器，$z_t \in \mathbb{R}^d$ 为低维潜特征（Latent Feature）。CNN 通过卷积层逐步聚合局部纹理、边缘与形状信息，经全连接层投影至紧凑的潜在空间，从而将高维像素观测压缩为适合值函数与策略网络处理的低维表征。然而，潜特征 z_t 的语义质量直接决定了下游强化学习算法的性能上限，这催生了对编码器训练目标的精细设计。

不变性表征的数学定义

数据增强（Data Augmentation）是提升视觉编码器鲁棒性的主流手段。其理论动机来源于不变性表征（Invariant Representation）的概念：对于任务无关的观测变换（如随机裁剪、颜色抖动、平移或频率掩盖），编码器所提取的潜特征应在语义层面保持稳定，不受变换引起的像素级扰动影响。

设 $\mathcal{T}$ 为一族数据增强变换的分布，$\tilde{o} = \mathcal{T}(o)$ 为经增强操作后的观测。不变性表征的目标可形式化表述为：

$$\forall \mathcal{T} \in \mathbb{T}: \quad \mathcal{F}\Big(E_\varphi(o)\Big) \approx \mathcal{F}\Big(E_\varphi(\mathcal{T}(o))\Big) \tag{2-41}$$

其中，$\mathcal{F}$ 为任意下游任务相关的泛函（如价值函数或策略映射）。在实践中，不变性目标通常通过对比学习（Contrastive Learning）或一致性正则化（Consistency Regularization）来实现，例如 RAD[laskin2020reinforcement]、DrQ[kostrikov2020image] 等方法要求同一观测的两个增强视图在潜空间中距离足够近：

$$\mathcal{L}_{\text{inv}} = \mathbb{E}_{o\sim\mathcal{D},\,\mathcal{T}_1,\mathcal{T}_2\sim\mathbb{T}}\left[\left\|E_\varphi(\mathcal{T}_1(o)) - \text{sg}\Big[E_\varphi(\mathcal{T}_2(o))\Big]\right\|_2^2\right] \tag{2-42}$$

其中，sg[·] 表示停止梯度算子（Stop-Gradient），用于防止表征坍缩（Representation Collapse）。不变性约束迫使编码器剥离增强操作引入的无关扰动，保留对决策任务真正有用的结构信息。

关键痛点：强数据增强对时间平滑性的破坏

尽管数据增强能够改善编码器对视觉扰动的鲁棒性，强数据增强（Strong Augmentation）——即变换幅度显著改变图像的低频结构，如大范围随机裁剪、频率域掩盖或强烈颜色变换——在强化学习中会引发一个深层的理论问题：马尔可夫决策过程的时间平滑性（Temporal Smoothness）遭受破坏。

时间平滑性要求相邻时间步的状态转移在潜空间中保持局部连续性，即对于真实状态序列 (s_t, s_{t+1})，其编码表征满足：

$$\Big\|E_\varphi(o_{t+1}) - E_\varphi(o_t)\Big\|_2 \le \kappa \left\|o_{t+1} - o_t\right\|_2 \tag{2-43}$$

其中，$\kappa > 0$ 为利普希茨常数（Lipschitz Constant），刻画了编码器的局部平滑程度。

当施加强数据增强 $\mathcal{T}$ 时，同一时间步的观测 o_t 被映射至两个语义相异的增强视图 $\tilde{o}_t^{(1)}$ 与 $\tilde{o}_t^{(2)}$，而相邻时间步 $\tilde{o}_t$ 与 $\tilde{o}_{t+1}$ 因独立采样增强操作而彼此无关。在此情形下，时序差分（Temporal Difference）自举所依赖的目标值为：

$$y_t = r_t + \gamma \min_j Q_{\bar{\theta}_j}\Big(E_\varphi\Big(\mathcal{T}^{(j)}(o_{t+1})\Big),\, \tilde{a}_{t+1}\Big) \tag{2-44}$$

其中 $\mathcal{T}^{(j)}$ 为对 o_{t+1} 的第 j 次随机采样。目标值 y_t 的方差可分解为：

$$\text{Var}(y_t) = \gamma^2\,\text{Var}\Big(Q_{\bar{\theta}}\Big(E_\varphi(\mathcal{T}(o_{t+1})), \tilde{a}_{t+1}\Big)\Big) \ge \gamma^2\,\mathbb{E}\left[\left(\frac{\partial Q}{\partial z}\right)^2\right] \cdot \text{Var}\Big(E_\varphi(\mathcal{T}(o_{t+1}))\Big) \tag{2-45}$$

上式表明，强增强所引入的编码方差 $\text{Var}(E_\varphi(\mathcal{T}(o_{t+1})))$ 经 Q 函数梯度的放大后，直接转化为目标值 y_t 的高方差。目标值的随机波动等价于在贝尔曼更新中注入系统性噪

声，致使 Critic 的梯度方向在相邻迭代间剧烈震荡，训练曲线呈现高度不稳定性，甚至导致 Q 值发散。

此问题的根源在于：数据增强操作集合 $\mathbb{T}$ 的设计与具体强化学习任务的奖励结构、状态转移动力学之间存在天然的语义错位——增强对于分类任务可能是无害的标签保持变换，但对于依赖精确时序信息进行 TD 自举的强化学习任务，相同的增强却可能破坏决策所必需的物理一致性。这一矛盾揭示了一个核心需求：针对强化学习任务，数据增强的选择不应遵循与视觉识别任务相同的启发式规则，而需要一种能够感知当前任务动力学属性的增强选择机制，以在不变性收益与时间平滑性代价之间取得原则性权衡。这一需求正是本文后续提出 PICK 算法的直接理论动因。

2.3.2 掩码建模与自监督特征重建

数据流形假设

高维视觉观测的可学习性根植于数据流形假设（Data Manifold Hypothesis）：自然场景中由物理系统产生的图像序列，尽管在像素空间中具有极高维度，却实际分布在一个远低维的黎曼流形（Riemannian Manifold）$\mathcal{M} \subset \mathbb{R}^{H\times W\times C}$ 附近，且该流形的内在维度（Intrinsic Dimensionality）由物理系统的真实自由度数目所决定：

$$\dim(\mathcal{M}) \approx \dim(\mathcal{S}) \ll H \cdot W \cdot C \tag{2-46}$$

这一假设的物理内涵在于：机器人系统的关节角度、速度、接触力等状态变量之间受到运动学约束、动力学方程与接触力学定律的严格约束，使得合法的状态轨迹被限制在物理上可行的低维子流形上。流形上的相邻点对应物理上连续的状态演化，流形的切空间局部描述了合法的状态变化方向。在此假设下，表征学习的目标等价于：寻找从像素空间到流形内在坐标的高保真映射，从而在低维潜空间中保留物理系统的几何结构与动力学约束。

掩码自编码器的架构与重建目标

掩码自编码器（Masked Autoencoder, MAE）[he2022masked]是实现上述流形学习目标的有效自监督框架。其核心思想源于完形填空（Cloze Test）的认知原理：若模型能够从部分遮盖的输入中精确重建被掩盖的区域，则必然已学得数据的全局结构与局部语义之间的内在关联，这恰好对应于对流形几何的隐式编码。

MAE 由编码器 $E_\varphi : \mathbb{R}^{H\times W\times C} \to \mathbb{R}^d$ 与解码器 $D_\psi : \mathbb{R}^d \to \mathbb{R}^{H\times W\times C}$ 构成。给定原始观测 $s \in \mathbb{R}^{H\times W\times C}$，首先施加随机掩码操作 $M \in \{0,1\}^{H\times W}$（$M_{ij} = 0$ 表示该位置被遮盖），得到部分可见输入：

$$\tilde{s} = s \odot M \tag{2-47}$$

其中，$\odot$ 表示逐元素乘积（Hadamard Product），实践中 M 通常对图像块（Patch）级别进行采样，掩码比例 $\rho \in [0.5, 0.75]$ 以确保任务难度足够。

编码器对可见区域进行特征提取，解码器以潜特征与可学习掩码标记（Mask Token）为输入，尝试重建完整观测。训练目标为最小化重建均方误差：

$$\min_{\varphi,\psi} \mathbb{E}_{s\sim\mathcal{D},M\sim\mathcal{M}}\left[\left\|D_\psi\Big(E_\varphi(s\odot M)\Big)-s\right\|_2^2\right] \tag{2-48}$$

在实践中，损失计算通常仅限于被掩盖区域以提高学习效率：

$$\mathcal{L}_{\text{recon}}(\varphi,\psi)=\mathbb{E}_{s\sim\mathcal{D},M\sim\mathcal{M}}\left[\frac{1}{|\bar{M}|}\sum_{(i,j):\,M_{ij}=0}\left\|\Big[D_\psi\Big(E_\varphi(s\odot M)\Big)\Big]_{ij}-s_{ij}\right\|_2^2\right] \tag{2-49}$$

其中，$|\bar{M}|=\sum_{ij}(1-M_{ij})$ 为被掩盖区域的总面积。

自监督重建的理论可行性

MAE 重建目标的理论可行性建立在以下因果链上：其一，被掩盖区域的精确重建要求模型对未掩盖区域的特征进行”语境推理”（Contextual Reasoning），即理解相邻图像块之间的视觉依赖关系；其二，视觉图像块之间的依赖关系在物理系统中由系统的几何结构、光照模型与运动学约束决定，因此语境推理过程隐式地要求模型学习这些物理约束；其三，编码器 E_φ 为了支持解码器 D_ψ 完成高质量重建，必须将可见区域的信息压缩为包含全局物理状态信息的紧凑表征 $z=E_\varphi(\tilde{s})$，而非仅编码局部纹理特征。

这一自监督过程等价于将潜特征 z 约束在数据流形 $\mathcal{M}$ 的内在坐标上：若 z 偏离流形，则解码器 D_ψ 无法从该坐标重建出物理合法的观测，训练损失将产生显著惩罚，迫使 z 回归流形。形式上，最优编码器 E_φ^* 满足：

$$E_\varphi^*(s)\approx\Phi(s),\quad \forall s\in\mathcal{M} \tag{2-50}$$

其中，$\Phi:\mathcal{M}\to\mathbb{R}^d$ 为流形 $\mathcal{M}$ 到潜空间的同胚映射（Homeomorphism），即一一连续的双向映射，保留了流形的拓扑结构与局部度量关系。因此，MAE 以纯数据驱动的方式，隐式学习了物理系统状态空间的几何编码，为下游强化学习中的价值函数估计提供了信息充分的低维特征基础。

关键痛点：联合训练中的梯度冲突

在强化学习框架下，一种直觉性的方法是将重建损失 $\mathcal{L}_{\text{recon}}$ 作为辅助任务与 TD 损失 $\mathcal{L}_{\text{TD}}$ 联合优化，对共享编码器 E_φ 进行端到端训练：

$$\mathcal{L}_{\text{joint}}(\varphi)=\mathcal{L}_{\text{TD}}(\varphi)+\lambda\,\mathcal{L}_{\text{recon}}(\varphi,\psi) \tag{2-51}$$

然而，这一联合训练范式在实践中面临严重的梯度冲突（Gradient Conflict）问题。设 $g_{\mathrm{TD}} = \nabla_{\varphi}\mathcal{L}_{\mathrm{TD}}$ 与 $g_{\mathrm{recon}} = \nabla_{\varphi}\mathcal{L}_{\mathrm{recon}}$ 分别为两个任务施加在编码器参数上的梯度，梯度冲突的严重程度由其余弦相似度刻画：

$$\cos\angle(g_{\mathrm{TD}},\, g_{\mathrm{recon}}) = \frac{\langle g_{\mathrm{TD}},\, g_{\mathrm{recon}}\rangle}{\|g_{\mathrm{TD}}\|_2 \cdot \|g_{\mathrm{recon}}\|_2} \tag{2-52}$$

当 $\cos\angle(g_{\mathrm{TD}}, g_{\mathrm{recon}}) < 0$ 时，两梯度方向相反，合并梯度 $g_{\mathrm{TD}} + \lambda g_{\mathrm{recon}}$ 既无法充分减小 $\mathcal{L}_{\mathrm{TD}}$ 也无法充分减小 $\mathcal{L}_{\mathrm{recon}}$，编码器陷入两个目标之间的博弈均衡，表征质量显著退化。

这一冲突的产生有其深刻的几何根源。TD 损失的梯度 g_{TD} 所传递的信号来自贝尔曼残差，其方向由当前 Q 值的高估或低估方向决定，本质上是一种间接的、通过奖励信号反向推断出的特征选择压力——它倾向于强化与当前奖励结构相关的特征维度，对价值估计无关的特征施加抑制。相比之下，重建损失的梯度 g_{recon} 来自像素级重建误差，所传递的是对全局物理状态信息的保留压力——它倾向于均匀地保留所有具有重建价值的视觉特征，包括背景纹理、光照变化等对决策无关但对像素重建有贡献的信息。

两者的目标在特征选择上存在本质矛盾：TD 学习驱使表征向任务特定的低维决策子空间坍缩，而重建学习驱使表征向全局物理状态的高维流形展开。若在共享编码器上直接叠加两种梯度，则重建目标提取的流形结构将被 TD 更新的噪声梯度所污染，编码器既无法学得用于精确值函数估计的任务相关特征，也无法维护用于重建的全局状态表征，最终导致两项任务的性能均低于各自独立训练的基线。

这一梯度冲突分析表明，自监督重建与 TD 优化在同一编码器参数空间的共存需要精细的梯度流控制机制。必须设计一种表征学习与决策优化解耦的训练范式——允许重建任务在编码器中自由构建物理状态的流形表征，同时防止 TD 梯度对该流形结构造成破坏性干扰。这一原则性要求正是本文后续提出 Masked-IQL 梯度截断机制的核心理论动因。

3 算法与代码

学校并未对算法或代码的排版格式作出限定，因此可以自行修改。

3.1 算法

在仔细研究后，本模板使用了基于 `algorithm2e` 宏包的算法排版工具，而没有使用 `algorithmicx (algpseudocode)`。同时，需要提醒的是，`algpseudocode` 在制作竖直定界线方面有一些问题，而能够较好的实现算法自动分段；`algorithm2e` 则相反，且这两个宏包相互冲突。

算法的具体编写方式请自行查阅宏包，即 `texdoc algorithm2e`，本模板已预先定义了 Do-While 循环即 `\Do{cond}{code}`。

```
\begin{algorithm}[H]
  \SetAlgoLined
  \KwData{this text}
  \KwResult{how to write algorithm with \LaTeX2e }

  initialization\;
  \While{not at end of this document}{
    read current\;
    \eIf{understand}{
      go to next section\;
      current section becomes this one\;
      }{
      go back to the beginning of current section\;
      }
    }
  \caption{How to write algorithms}
\end{algorithm}
```

算法 3-1 How to write algorithms

Data: this text

Result: how to write algorithm with LaTeX2e

```
initialization;
while not at end of this document do
    read current;
    if understand then
        go to next section;
        current section becomes this one;
    else
        go back to the beginning of current section;
    end
end
```

算法 3-2 Simulation-optimization heuristic

Data: current period t, initial inventory I_{t-1}, initial capital B_{t-1}, demand samples

Result: Optimal order quantity Q_t^*

$r \leftarrow t$;

$\Delta B^* \leftarrow -\infty$;

while $\Delta B \leq \Delta B^*$ *and* $r \leq T$ **do**

  $Q \leftarrow \arg\max_{Q \geq 0} \Delta B_{t,r}^{Q}(I_{t-1}, B_{t-1})$;

  $\Delta B \leftarrow \Delta B_{t,r}^{Q}(I_{t-1}, B_{t-1})/(r - t + 1)$;

  if $\Delta B \geq \Delta B^*$ **then**

    $Q^* \leftarrow Q$;

    $\Delta B^* \leftarrow \Delta B$;

  end

  $r \leftarrow r + 1$;

end

算法 3-3 How to write algorithms

Data: this text

Result: how to write algorithm with LaTeX2e

```
initialization;
while not at end of this document do
    read current;
    repeat
        do these things;
    until this end condition;
    if understand then
        go to next section;
        current section becomes this one;
    else
        go back to the beginning of current section;
    end
    do
        do these things;
    while this end condition;
end
```

3.2 导入代码

从现有文件导入源码，使用 `lstlisting` 宏包，本模板预先定义了一基本格式 `sty_basic` 以供使用，可以自定义新的样式。

```
[style=sty_basic,
  language=matlab,
  caption={标准粒子群算法},
  label={lst:a_label}]{./Codes/pso.m}
```

源码 3-1 标准粒子群算法

```
% 标准粒子群算法 来自[https://zhuanlan.zhihu.com/p/57288027]
clc;
clear all;


```

```
c1=1.49445;            %加速系数，这里1.49445为某一论文中取值，能使PSO发挥不错的性能
c2=1.49445;
maxg=1000;             %迭代次数
sizepop=20;            %种群规模
D=30;                  %维度
popmax=600;            %种群上下边界值，这里使用Griewank函数，测试范围为（-600，600）
popmin=-popmax;        %取对称区间
Vmax=0.15*popmax;      %速度限定，通常在搜索范围的10%~20%均可，这里作者取15%
Vmin=0.15*popmin;


%%产生初始粒子位置及速度
for i=1:sizepop                                  %将popsize个粒子依次初始化
    pop(i,:)=popmax*rands(1,D);                  %初始位置
    V(i,:)=Vmax*rands(1,D);                      %初始速度
    fitness(i)=Griewank(pop(i,:));               %计算适应度，Griewank为用来测试的函数
                                                 %fitness只作每次迭代变量临时储存，不具有记忆性
end


%寻找最优个体
%因目前第一代，故其当前取值即历史最优，全部赋值即可
[bestfitness bestindex]=min(fitness);            %从fitness中寻找最小值，依次返回值和索引，由变量接收
pBest=pop;                                       %个体历史最佳位置
gBest=pop(bestindex,:);                          %全局历史最佳位置
fitnesspbest=fitness;                            %个体历史最佳适应度
fitnessgbest=bestfitness;                        %全局历史最佳适应度


%%迭代寻优
for i=1:maxg                  %每一代循环
    for j=1:sizepop           %每个粒子循环

        %速度更新
        w=0.8;                %w即omega，惯量权重，这里取固定值
        V(j,:)=w*V(j,:)+c1*rand*(pBest(j,:)-pop(j,:))+c2*rand*(gBest-pop(j,:));
        %越界处理
        V(j,find(V(j,:)>Vmax))=Vmax;
        V(j,find(V(j,:)<Vmin))=Vmin;

```

```
        %位置更新
        pop(j,:)=pop(j,:)+V(j,:);
        %越界处理
        pop(j,find(pop(j,:)>popmax))=popmax;
        pop(j,find(pop(j,:)<popmin))=popmin;

        %计算适应度值
        fitness(j)=Griewank(pop(j,:));

        %个体历史最优更新
        if fitness(j)<fitnesspbest(j)
            pBest(j,:)=pop(j,:);
            fitnesspbest(j)=fitness(j);
        end

        %群体历史最优更新
        if fitness(j)<fitnessgbest
            gBest=pop(j,:);
            fitnessgbest=fitness(j);
        end
    end
    result(i)=fitnessgbest;     %储存历代全局历史最优适应度值
end


semilogy(result);       %对y轴取对数
grid on;                %打格

%坐标含义说明
title('适应度曲线 ');
xlabel('进化代数');
ylabel('适应度');
```

4 参考文献与交叉引用

注意，当引用时出现 [?] 时，请注意查看辅助文件是否正常生成，此种问题不是模板造成的，请自行解决。

4.1 公式、图表的引用

4.1.1 引用公式

引用公式使用 `\eqref{label}` 命令，将引用公式的编号（带括号）：

```
如式 \eqref{eqn:c1:diff} 所示
```

如式 (**??**) 所示

4.1.2 引用其他内容

其他浮动体引用请使用 `\ref{label}` 命令，将引用其编号（无括号）：

```
如图 \ref{subfig:icon} 所示 \\
如表 \ref{tab:methodcompare} 所示 \\
如算法 \ref{algorithm} 所示 \\
如源码 \ref{lst:a_label} 所示
```

如图 **??** 所示
如表 **??** 所示
如算法 3-2 所示
如源码 3-1 所示

4.2 参考文献

1. 参考文献的著录格式应符合国家标准 GB/T 7714-2015《文后参考文献著录规则》。参考文献中每条项目应齐全。
2. 参考文献里面标点符号：英文文献用半角, 中文文献用全角。

1. 文后著录的参考文献务必实事求是。论文中引用过的文献必须著录，未引用的文献不得出现。应遵循学术道德规范，避免涉嫌抄袭、剽窃等学术不端行为。
2. 参考文献一般应是作者亲自考察过的对学位论文有参考价值的文献，除特殊情况外，一般不应间接引用。
3. 参考文献应有权威性，要注意引用最新的文献。
4. 参考文献的数量：博士学位论文，一般应在 80 篇以上，其中，期刊文献 60 篇以上，国外文献 30 篇以上，均以近 5 年的文献为主。硕士学位论文，一般应在 30 篇以上，其中，期刊文献不少于 20 篇，国外文献不少于 10 篇，均以近 5 年的文献为主。对于申请专业学位的学位论文，参考文献的数量可参照执行。

模板使用 biblatex 编译参考文献，默认采用顺序编码制，有多种引用参考文献的方式，请自行查阅 biblatex-gbt-7715-2015 宏包，即 `texdoc biblatex-gbt-7714-2015`。

在导言区使用 `\addbibresource{path/to/.bib file}` 添加参考文献数据库，默认参考文献数据库位于./References/ 下。

这里主要举例三种引用方式，使用 `\cite{ref}` 的引用结果作为上标出现在正文中，使用 `\parencite{ref}` 的引用结果作为正文内容（一个名词）出现在正文中，使用 `\footfullcite{ref}` 的引用结果作为脚注内容在脚注部分出现。

```
这是一个比较常见的问题 \cite{barella_situ_2021}。可以发现 xxxx
  \cite{atta_enhanced_2021}。\\

文献\parencite{张燕2013电气自动化在电气工程中的应用探讨} 提出了 xxx，文献
  \parencite{黄雪芳2012探讨电气工程中自动化技术的应用} 则提出了 yyy。
```

这是一个比较常见的问题[1]。可以发现 xxxx[2]。

文献[3] 提出了 xxx，文献 [4] 则提出了 yyy。

[①]根据 zzz 发布的报告[②]，可以发现[③]

① 这是脚注 1

② 王磊, 等. 电气自动化控制设备可靠性探究[J]. 科技传播, 2011, 19: 51-62.

③ 这是脚注 2

5 非正文部分的要求

5.1 摘要

摘要内容要求

内容一般包括：从事这项研究工作的目的和意义；完成的工作（作者独立进行的研究工作及相应结果的概括性叙述）；获得的主要结论（这是摘要的中心内容）。博士学位论文摘要应突出论文的创新点，硕士学位论文摘要应突出论文的新见解。

中文摘要主体格式

1. 论文摘要由摘要正文、关键词、论文类型、资助申明等部分组成。
2. 博士学位论文摘要正文为 1000 字 (word) 左右，硕士学位论文摘要正文为 600 字 (word) 左右。
3. 摘要中一般不用图、表、化学结构式、非公知公用的符号和术语。
4. 如果论文的主体工作得到了有关基金资助，应在摘要第一页的页脚处标注：本研究得到某某基金（编号：）资助。（五号）

英文摘要主体格式

1. 用词准确，符合语法；
2. 关键词按相应专业的标准术语写出，尽量从《英语主题词表》中摘选；
3. 如果论文的主体工作得到了有关基金资助，应用英文在摘要第一页的页脚处标注：本研究得到某某基金（编号：）资助；
4. 中文摘要和英文摘要均不要求学位申请人及其指导教师签字。
5. 摘要正文每段开头不空格，每段之间空一行；

关键词要求

关键词由 3～5 个组成。关键词应从《汉语主题词表》中摘选，当《汉语主题词表》的词不足以反映主题时，可由申请人设计关键词，但须加注。每一关键词之间用分号分开，最后一个关键词后不打标点符号。由申请人设计的关键词，须在该关键词的右上角标注 *，并在该页的页脚处注明“* 表示非汉语主题词”。

论文类型要求

论文类型包括：a. 理论研究（Theoretical Research）；b. 应用基础 (Application Fundamentals)；c. 应用研究 (Application Research)；d. 研究报告 (Research Report)；e. 设计报告 (Design Report)；f. 案例分析 (Case Study)；g. 调研报告 (Investigation Report)；h. 产品研发 (Product Development)；i. 工程设计 (Engineering Design)；j. 工程/项目管理 (Engineering/Project Management)；k. 其它（Others）。

5.2 主要符号表

1. 如果论文中使用了大量的物理量符号、标志、缩略词、专门计量单位、自定义名词和术语等，应将全文中常用的这些符号及意义列出。如果上述符号和缩略词使用数量不多，可以不设专门的主要符号表，但在论文中出现时须加以说明。
2. 论文中主要符号应全部采用法定单位，特别要严格执行 GB3100～3102—93 有关“量和单位”的规定。单位名称的书写，可以采用国际通用符号，也可以用中文名称，但全文应统一，不得两种混用。
3. 缩略词应列出中英文全称。
4. 主要符号表正文统一左缩进一个字符。

5.3 攻读学位期间取得的研究成果

1. 已发表或已录用的学术论文、已出版的专著/译著、已获授权的专利按参考文献格式列出。
2. 科研获奖，列出格式为：获奖人（排名情况）. 项目名称. 奖项名称及等级，发奖机构，获奖时间. 。
3. 与学位论文相关的其它成果参照参考文献格式列出。
4. 全部研究成果连续编号编排。
5. 用于双盲评审的论文，只列出已发表的学术论文的篇名、发表刊物名称，必须隐去各类论文检索号、期号、卷号、页码；专利号；日期等。

5.4 答辩委员会会议决议

1. 填写内容应与学位（毕业）审批材料中答辩委员会决议书一致。
2. 无需签名。
3. 盲审论文仅保留“答辩委员会会议决议”标题

6 本模板已载入的 Packages

expl3	ifxetex	xcolor	tikz	tikz-3dplot	zhnumber	datetime2	indentfirst
setspace	etoolbox	xpatch	xparse	calc	ulem	ifthen	realboxes
blindtext	zhlipsum	amsmath	amssymb	amsthm	thmtools	glossaries	upgreek
pifont	array	commath	siunitx	mathtools	mathspec	geometry	ifoddpage
emptypage	pdfpages	xeCJK	fontenc	lmodern	anyfontsize	mathrsfs	amsfonts
ctex	ifplatform	graphicx	algorithm2e	tcolorbox	listings	enumitem	footmisc
fancyvrb	fancyhdr	titlesec	float	newfloat	multirow	longtable	tabu
tabularx	xltabular	booktabs	caption	subcaption	xurl	hyperref	bookmark
titletoc	tocloft	biblatex	appendix				

致　谢

致谢中主要感谢导师和对论文工作有直接贡献和帮助的人士和单位。

一般致谢的内容有：

(一) 对指导或协助指导完成论文的导师；

(二) 对国家科学基金、资助研究工作的奖学金基金、合同单位、资助或支持的企业、组织或个人；

(三) 对协助完成研究工作和提供便利条件的组织或个人；

(四) 对在研究工作中提出建议和提供帮助的人；

(五) 对给予转载和引用权的资料、图片、文献、研究思想和设想的所有者；

(六) 对其他应感谢的组织和个人。

致谢言语应谦虚诚恳，实事求是。字数不超过 1000 汉字

用于双盲评审的论文，此页内容全部隐去。

参考文献

[1] BARELLA M, VIOLI I L, GARGIULO J, et al. In Situ Photothermal Response of Single Gold Nanoparticles through Hyperspectral Imaging Anti-Stokes Thermometry[J/OL]. Acs Nano, 2021, 15(2): 2458-2467. DOI: 10.1021/acsnano.0c06185.

[2] ATTA A. Enhanced dielectric properties of flexible Cu/polymer nanocomposite films[J/OL]. Surface Innovations, 2021, 9(1): 17-24. DOI: 10.1680/jsuin.20.00020.

[3] 张燕. 电气自动化在电气工程中的应用探讨[J]. 电子技术与软件工程, 2013, 17: 199-199.

[4] 黄雪芳. 探讨电气工程中自动化技术的应用[D]. 某地: 某大学, 2012.

[5] 王磊, 薛双苓. 电气自动化控制设备可靠性探究[J]. 科技传播, 2011, 19: 51-62.

[6] 王永华, 张, 李, 等. 现代电气控制及 PLC 应用技术[M]. 北京: 北京航空航天大学出版社, 2013.

[7] 刘海龙. 浅谈电气自动化的现状与发展方向[J]. 黑龙江科技信息, 2010, 6(5).

[8] 陈众励, 赵济安, 邵民杰. 建筑电气节能技术综述[J]. 低压电器, 2007, 4: 1-5.

[9] SACHDEVA B, KAUSHIK R, ARORA S, et al. Effect of processing conditions on the stability of native vitamin A and fortified retinol acetate in milk[J/OL]. International Journal for Vitamin and Nutrition Research, 2021, 91(1-2): 133-142. DOI: 10.1024/0300-9831/a000617.

[10] WU L, DING X, ZHENG Z, et al. Doublely-doped Mg-Al-Ce-V2O74- LDH composite film on magnesium alloy AZ31 for anticorrosion[J/OL]. Journal of Materials Science & Technology, 2021, 64: 66-72. DOI: 10.1016/j.jmst.2019.09.031.

[11] LUO J, GAO S, LUO H, et al. Superhydrophobic and breathable smart MXene-based textile for multifunctional wearable sensing electronics[J/OL]. Chemical Engineering Journal, 2021, 406: 126898. DOI: 10.1016/j.cej.2020.126898.

[12] HU Z, LI S, WANG S, et al. Encapsulation of menthol into cyclodextrin metal-organic frameworks: Preparation, structure characterization and evaluation of complexing capacity[J/OL]. Food Chemistry, 2021, 338: 127839. DOI: 10.1016/j.foodchem.2020.127839.

[13] QIAN C, YIN J, ZHAO J, et al. Facile preparation and highly efficient photodegradation performances of self-assembled Artemia eggshell-ZnO nanocomposites for wastewater treatment[J/OL]. Colloids and Surfaces a-Physicochemical and Engineering Aspects, 2021, 610: 125752. DOI: 10.1016/j.colsurfa.2020.125752.

[14] EVANS J D, KRAUSE S, FERINGA B L. Cooperative and synchronized rotation in motorized porous frameworks: impact on local and global transport properties of confined fluids[J/OL]. Faraday Discussions, 2021, 225(0): 286-300. DOI: 10.1039/d0fd00016g.

附录 A 公式推导

A.1 第一章

附录编号依次编为附录 A，附录 B。附录标题各占一行，按一级标题编排。每一个附录一般应另起一页编排，如果有多个较短的附录，也可接排。附录中的图表公式另行编排序号，与正文分开，编号前加“附录 A-”字样。

本部分内容非强制性要求，如果论文中没有附录，可以省略《附录》。

定义 附录 A.1 (向量空间) 设 X 是一个非空集合，$\mathbb{F}$ 是一个数域 (实数域 $\mathbb{R}$ 或者复数域 $\mathbb{C}$)。如果在 X 上定义了加法和数乘两种运算，并且满足以下 8 条性质：

1. 加法交换律，$\forall x, y \in X$，$x + y = y + x \in X$；
2. 加法结合律，$\forall x, y, z \in X$，$(x + y) + z = x + (y + z)$；
3. 加法的零元，$\exists\, 0 \in X$，使得 $\forall x \in X$，$0 + x = x$；
4. 加法的负元，$\forall x \in X$，$\exists\ -x \in X$，使得 $x + (-x) = x - x = 0$。
5. 数乘结合律，$\forall \alpha, \beta \in \mathbb{F}$，$\forall x \in X$，$(\alpha\beta)x = \alpha(\beta x) \in X$；
6. 数乘分配律，$\forall \alpha \in \mathbb{F}$，$\forall x, y \in X$，$\alpha(x + y) = \alpha x + \alpha y$；
7. 数乘分配律，$\forall \alpha, \beta \in \mathbb{F}$，$\forall x \in X$，$(\alpha + \beta)x = \alpha x + \beta x$；
8. 数乘的幺元，$\exists\, 1 \in \mathbb{F}$，使得 $\forall x \in X$，$1x = x$，

例子 附录 A.2 (矩阵空间) 所有 $m \times n$ 的矩阵在普通矩阵加法和矩阵数乘运算下构成一个向量空间 $\mathbb{C}^{m\times n}$。如果定义内积如下：

$$\langle A, B\rangle = \mathrm{tr}(B^H Q A) = \sum_{i=1}^{n} b_i^H Q a_i \tag{附录 A-1}$$

其中 a_i 和 b_i 分别是 A 和 B 的第 i 列，而 Q 是 Hermite 正定矩阵，那么 $\mathbb{C}^{m\times n}$ 构成一个 Hilbert 空间。

定理 附录 A.3 (Riesz 表示定理) 设 H 是 Hilbert 空间，H^* 是 H 的对偶空间，那么对 $\forall f \in H^*$，存在唯一的 $x_f \in H$，使得

$$f(x) = \langle x, x_f\rangle, \qquad \forall x \in H \tag{附录 A-2}$$

并且满足 $\|f\| = \|x_f\|$。

证明: 先证存在性，再证唯一性，最后正 $\|f\| = \|x_f\|$。 ■

附录 B　附录图表

附录 B-表 1 这是一个左对齐的表格示例

Symptom	Metric
Class that has many accessor methods and accesses a lot of external data	ATFD is more than a few
Class that is large and complex	WMC is high
Class that has a lot of methods that only operate on a proper subset of the instance variable set	TCC is low

(a) 红色校徽　　(b) 蓝色校徽

附录 B-图 1 校徽

附录 B-表 2 这是一个居中的表格示例

Symptom	Metric
Class	ATFD
Class	WMC
Class	TCC

攻读学位期间取得的研究成果

[1] Wei ZY, Tang YP, Zhao WH, et al. Rapid development technique for drip irrigation emitters[J]. RP Journal,UK., 2003, 9(2):104 110 (SCI: 000350930600051; EI: 03187452127).

[2] 魏正英, 唐一平, 卢秉恒. 滴灌管内嵌管状滴头的快速制造方法研究 [J]. 农业工程学报, 2001,17(2):55 58 (EI:01226526279,01416684777).

[3] 姜锡洲. 一种温热外敷药制备方案: 中国,88105607.3[P].1989-07-26.

[4]

[5]

[6]

[7]

用于双盲评审的论文，只列出已发表的学术论文的篇名、发表刊物名称，必须隐去各类论文检索号、期号、卷号、页码；专利号；日期等。

答辩委员会会议决议

论文提出了××××××

常规评阅人名单

本学位论文共接受 7 位专家评阅，其中常规评阅人 5 名，名单如下：

王 XX　教授　西安交通大学

李 XX　教授　XXXXXX 大学

田 XX　教授　XXXXXX 大学

学位论文独创性声明（1）

本人声明：所呈交的学位论文系在导师指导下本人独立完成的研究成果。文中依法引用他人的成果，均已做出明确标注或得到许可。论文内容未包含法律意义上已属于他人的任何形式的研究成果，也不包含本人已用于其他学位申请的论文或成果。

本人如违反上述声明，愿意承担以下责任和后果：

1. 交回学校授予的学位证书；
2. 学校可在相关媒体上对作者本人的行为进行通报；
3. 本人按照学校规定的方式，对因不当取得学位给学校造成的名誉损害，进行公开道歉。
4. 本人负责因论文成果不实产生的法律纠纷。

论文作者（签名）：　　日期：　　年　　月　　日

学位论文独创性声明（2）

本人声明：研究生　　所提交的本篇学位论文已经本人审阅，确系在本人指导下由该生独立完成的研究成果。

本人如违反上述声明，愿意承担以下责任和后果：

1. 学校可在相关媒体上对本人的失察行为进行通报；
2. 本人按照学校规定的方式，对因失察给学校造成的名誉损害，进行公开道歉。
3. 本人接受学校按照有关规定做出的任何处理。

指导教师（签名）：　　日期：　　年　　月　　日

学位论文知识产权权属声明

我们声明，我们提交的学位论文及相关的职务作品，知识产权归属学校。学校享有以任何方式发表、复制、公开阅览、借阅以及申请专利等权利。学位论文作者离校后，或学位论文导师因故离校后，发表或使用学位论文或与该论文直接相关的学术论文或成果时，署名单位仍然为西安交通大学。

论文作者（签名）：　　日期：　　年　　月　　日

指导教师（签名）：　　日期：　　年　　月　　日

（本声明的版权归西安交通大学所有，未经许可，任何单位及任何个人不得擅自使用）